

BÁO CÁO TÌM HIỂU NỀN TẢNG HUGGING FACE

Nguyễn Thành Bảo - MSSV: 24120023
Lớp: 24CTT6



Ngày 18 tháng 5 năm 2026

Mục lục

1	Giới thiệu tổng quát (Introduction)	3
2	Thông tin tổng quan (Overview)	3
2.1	Hugging Face là gì?	3
2.2	Các dịch vụ cung cấp	3
3	Chính sách giá (Pricing)	3
4	Chi tiết các Tasks phổ biến (NLP)	4
4.1	Text Classification (Phân loại văn bản)	4
4.2	Zero-shot Classification	4
4.3	Token Classification	5
5	Sử dụng Hub Python Library	5
6	Inference Providers và mức Miễn phí	5
7	So sánh InferenceClient và HTTP Requests	6
8	Các mã lỗi HTTP cần quan tâm	6
9	Triển khai Demo trên Hugging Face Spaces	6
10	Đề xuất luồng xử lý ứng dụng Du lịch	8
10.1	1. Phân tích cảm xúc review (Text Classification)	8
10.2	2. Phân loại ý định và trích xuất thực thể	8
10.3	3. Phân loại chủ đề của Review (Zero-shot Classification)	9
11	Tài liệu tham khảo	9

1 Giới thiệu tổng quát (Introduction)

Trong bối cảnh phát triển ứng dụng du lịch thông minh, việc thấu hiểu và phân tích dữ liệu từ người dùng (như đánh giá chuyến đi, nhu cầu tìm kiếm) đóng vai trò cốt lõi. Báo cáo này được thực hiện nhằm tìm hiểu nền tảng Hugging Face - một hệ sinh thái cung cấp các mô hình Trí tuệ nhân tạo (AI) và Xử lý ngôn ngữ tự nhiên (NLP) tiên tiến. Mục tiêu là ứng dụng các công cụ của Hugging Face để xây dựng các tính năng cốt lõi cho dự án như: phân tích cảm xúc đánh giá, trích xuất thực thể địa danh và phân loại chủ đề du lịch.

2 Thông tin tổng quan (Overview)

2.1 Hugging Face là gì?

Hugging Face là một nền tảng và cộng đồng mã nguồn mở hàng đầu dành cho Machine Learning (ML). Nền tảng này được ví như "GitHub của Machine Learning", nơi các nhà nghiên cứu và lập trình viên có thể lưu trữ, chia sẻ, khám phá và triển khai các mô hình AI, tập dữ liệu cũng như các ứng dụng web demo.

2.2 Các dịch vụ cung cấp

- **Model Hub:** Kho lưu trữ hơn 1 triệu mô hình pre-trained cho NLP, Computer Vision, Audio.
- **Dataset Hub:** Nền tảng chia sẻ dữ liệu huấn luyện đa ngôn ngữ và lĩnh vực.
- **Spaces:** Môi trường hosting miễn phí/trả phí để triển khai ứng dụng ML trực quan (hỗ trợ Streamlit, Gradio).
- **Serverless Inference API:** Cho phép gọi và chạy thử các mô hình trực tiếp qua API mà không cần tải model về máy tính.
- **Inference Endpoints:** Dịch vụ thuê máy chủ GPU chuyên dụng (có trả phí) để triển khai mô hình cho môi trường Production thực tế.

3 Chính sách giá (Pricing)

Hugging Face cung cấp hệ thống định giá linh hoạt theo mô hình Freemium:

- **Free Tier (Miễn phí):** Cung cấp quyền truy cập công khai vào Hub, sử dụng Spaces (phần cứng cơ bản CPU 16GB RAM) và Serverless Inference API với hạn mức (Rate limit) nhất định. Phù hợp cho sinh viên và phát triển thử nghiệm.
- **PRO Account (\$9/tháng):** Tăng giới hạn rate limit, ưu tiên cấp phát tài nguyên khi quá tải, và cấp quyền sử dụng tính năng ZeroGPU cho Spaces.
- **Pay-as-you-go:** Tính phí theo giờ (USD/h) khi người dùng thuê phần cứng mạnh (như Nvidia A10G, T4) cho Spaces hoặc Dedicated Endpoints.

4 Chi tiết các Tasks phổ biến (NLP)

Hugging Face chuẩn hóa các bài toán thành các "Tasks". Dưới đây là 3 task quan trọng cho xử lý văn bản:

4.1 Text Classification (Phân loại văn bản)

- **Mục đích:** Gán một nhãn (label) cho đoạn văn bản (VD: phân tích cảm xúc, spam).
- **Input/Output:** Input là chuỗi văn bản → Output là mảng `[{label, score}]` (nhãn và độ tin cậy).
- **Ví dụ model:** `distilbert-base-uncased-finetuned-sst-2-english`.
- **Giới hạn thường gặp:** Bị giới hạn độ dài context (thường là 512 tokens). Văn bản dài cần được cắt bớt (truncation).

4.2 Zero-shot Classification

- **Mục đích:** Phân loại văn bản vào các nhãn tùy chọn mà **không cần** huấn luyện (fine-tune) lại mô hình cho các nhãn đó.
- **Input/Output:** Input gồm Chuỗi văn bản + Danh sách các nhãn ứng cử → Output là xác suất tương ứng cho từng nhãn.
- **Ví dụ model:** `facebook/bart-large-mnli`.
- **Giới hạn thường gặp:** Tốc độ suy luận chậm và độ chính xác có thể không cao bằng mô hình đã được fine-tune chuyên biệt.

4.3 Token Classification

- **Mục đích:** Gán nhãn cho **từng từ** (token) trong câu. Thường dùng cho trích xuất thực thể (NER - Named Entity Recognition).
- **Input/Output:** Input là chuỗi văn bản → Output là danh sách các thực thể [{entity_group, word, start, end, score}].
- **Ví dụ model:** dslim/bert-base-NER.
- **Giới hạn thường gặp:** Phụ thuộc vào bộ từ vựng của Tokenizer, dễ nhận diện sai các từ viết tắt hoặc sai chính tả.



Hình 1: Minh họa nhận dạng thực thể (NER) thuộc tác vụ Token Classification

5 Sử dụng Hub Python Library

Thư viện `huggingface_hub` cho phép quản lý và tìm kiếm mô hình trực tiếp qua code thay vì dùng giao diện web.

Listing 1: Tìm kiếm mô hình phân loại văn bản tiếng Việt

```
from huggingface_hub import HfApi, ModelFilter

api = HfApi()
models = api.list_models(
    filter=ModelFilter(task="text-classification", language="vi"),
    sort="downloads", direction=-1, limit=3
)

for m in models:
    print(f"ID: {m.id} - L t t i : {m.downloads}")
```

6 Inference Providers và mức Miễn phí

- **Access Token:** Để gọi API, cần tạo token tại *Settings > Access Tokens* (chọn quyền READ). **Tuyệt đối không** hardcode token này ở phía Frontend.

- **Billing & Free credits:** Gói Free không yêu cầu nhập thẻ tín dụng. HF Serverless API cho phép gọi các mô hình miễn phí nhưng bị giới hạn số lượt gọi mỗi phút/giờ.
- **Kiểm soát quota:** HF trả về thông tin hạn mức qua HTTP Headers. Cụ thể header `x-ratelimit-remaining` cho biết số request còn lại trước khi bị chặn.

7 So sánh InferenceClient và HTTP Requests

Tiêu chí	InferenceClient (Thư viện HF)	HTTP Requests (Requests/Fetch)
Mức độ	High-level Wrapper	Low-level
Sử dụng	Ngắn gọn, hỗ trợ type-hinting, tự động xử lý payload JSON.	Phải tự setup Headers (Authorization) và cấu trúc JSON body.
Xử lý lỗi	Tự động văng (raise) các Exception của Python để đọc.	Cần tự check <code>status_code</code> và parse lỗi.
Phù hợp	Backend viết bằng Python.	Ngôn ngữ khác (JS, C++) hoặc hệ thống cấm cài thư viện bên ngoài.

8 Các mã lỗi HTTP cần quan tâm

- **401 Unauthorized:** Token không hợp lệ hoặc không được gửi kèm.
- **403 Forbidden:** Không có quyền truy cập (thường gặp ở các Gated Models yêu cầu người dùng phải ấn đồng ý điều khoản trên web HF trước).
- **404 Not Found:** Model ID sai hoặc model đang ở trạng thái Private.
- **410 Gone:** Model chưa được load lên bộ nhớ (Cold start). Cần đợi vài phút để hệ thống khởi động.
- **429 Too Many Requests:** Quá hạn mức miễn phí. Cần áp dụng chiến lược thử lại (Retry with backoff).


9 Triển khai Demo trên Hugging Face Spaces

Spaces cung cấp máy chủ miễn phí (2 vCPU, 16GB RAM) để chạy giao diện ứng dụng.


1. **Tạo Space:** Chọn framework Streamlit.
2. **Cấu trúc tệp tin:**
 - `requirements.txt`: Khai báo thư viện (VD: streamlit, requests).
 - `app.py`: Chứa logic mã nguồn Python và giao diện.
3. **Bảo mật Token:** Vào *Settings > Variables and secrets* của Space để lưu `HF_TOKEN`. Gọi ra trong code bằng `os.environ.get("HF_TOKEN")`.

Select the Space SDK

You can choose between [Gradio](#), [Docker](#), or [Static](#) to host your Space.




Choose a Docker template:



Hình 2: Giao diện ứng dụng web được cấu hình qua tệp app.py trên Spaces

10 Đề xuất luồng xử lý ứng dụng Du lịch

Project: MLOps, AIOps, LLMOps, and Deploying an Application with GitHub Actions and AWS EKS



Hình 3: Sơ đồ phân tích dữ liệu văn bản thô qua kiến trúc Pipeline NLP

10.1 1. Phân tích cảm xúc review (Text Classification)

- **Input:** User nhập: "Khách sạn sạch sẽ nhưng nhân viên thái độ kém."
- **Processing:** Gửi vào mô hình Multilingual Sentiment Analysis.
- **Output:** Kết quả: Negative (0.75).
- **Action:** Lưu điểm số vào DB để đánh giá chất lượng dịch vụ của đối tác.

10.2 2. Phân loại ý định và trích xuất thực thể

- **Input:** Khách chat: "Tìm cho tôi tour đi Vịnh Hạ Long giá rẻ."
- **Processing:**
 1. *Intent:* Dùng Zero-shot classification → Trả về "**Tìm Tour**".
 2. *Entity:* Dùng Token classification (NER) → Trích xuất **Location** = "**Vịnh Hạ Long**".
- **Action:** Đẩy biến Location vào SQL/Vector DB để query các gói tour phù hợp.

10.3 3. Phân loại chủ đề của Review (Zero-shot Classification)

- **Input:** "Đồ ăn hải sản tươi ngon nhưng đường đi khá bụi bẩn."
- **Processing:** Dùng Zero-shot với `multi_label=True` và các nhãn: `["Ấm thực", "Giao thông", "Lưu trú"]`.
- **Output:** Ấm thực: 0.95, Giao thông: 0.88, Lưu trú: 0.10.
- **Action:** Tự động gắn tag `#Ấm_thực` và `#Giao_thông` để hỗ trợ bộ lọc tìm kiếm review cho khách hàng sau.

11 Tài liệu tham khảo

Tài liệu

- [1] Hugging Face. *Hugging Face Documentation Hub*. <https://huggingface.co/docs>
- [2] Hugging Face. *Tasks Explained*. <https://huggingface.co/tasks>
- [3] Hugging Face. *Serverless Inference API Documentation*. <https://huggingface.co/docs/api-inference/index>